

MedOps Copilot 项目设计文档

医药合规与临床运营 Agent：项目需求 · 技术实现 · 约束

版本：v0.1（设计基线） | 状态：开发中 | 数据：全程公开 / 脱敏 / 合成

一、项目定位与目标

1.1 一句话定位

面向医学事务（MA）、药物警戒（PV）和临床运营（CO）团队的知识与运营助手：**只基于经过版本校验、权限校验的原文证据回答，答不了就拒答或升级给人，并且能在人工审批下持续改进。**

1.2 要解决的核心问题

传统 RAG 的问题	本项目的对应设计
引用失效版本的说明书 / 方案	PostgreSQL 事实平面维护文档状态与版本链，向量库只做候选召回
遗漏剂量、时间窗、方案编号等精确条款	BM25 + 向量 + RRF + Reranker 混合检索
生成无依据医学结论	Evidence Verify 节点逐项核验，未支持即拒答
没有部门权限隔离	文档 ACL + 部门身份在检索层强制过滤
没有审计与回放	Trace 全链路记录，支持重放
反馈无法转化为改进	受控自进化 Loop，人工审批后灰度发布

1.3 项目范围

在范围内

- 药品说明书、临床试验方案、SOP、医学指南的检索与合规问答
- 不良事件线索提取、超说明书用药检查、方案偏离核验、医学引用验证
- 部门权限控制、执行审计、反馈驱动的策略改进
- 对外提供 REST API 与只读 MCP Server

明确不在范围内

- 任何形式的诊断、处方、个体化用药建议
- 处理真实患者数据（PHI / PII）
- 在线自动修改生产策略（无人工审批）
- 对文档进行写入 / 修改（MCP 只读）

二、项目需求

2.1 用户角色

角色	典型任务	权限域
医学事务专员	说明书条款查询、适应证核对、医学引用验证	MA 文档域
药物警戒专员	不良事件线索提取、时间窗判断、报告要求查询	PV 文档域
临床运营专员	方案偏离核验、SOP 步骤查询、访视窗口计算	CO 文档域
知识管理员	文档入库、版本发布 / 归档、ACL 配置	管理后台
策略审核员	审批 Loop 生成的候选策略、查看回放报告	治理后台
外部 Agent	通过 MCP 调用只读检索能力	继承调用用户身份

2.2 功能需求

F1 可信问答（核心）

- F1.1 用户提问后，系统必须走完整状态机 `Intent` → `Retrieve` → `Evidence Verify` → `Safety Check` → `Answer / Escalate`，不允许跳过检索直接生成。
- F1.2 每条答案必须附带引用：文档 ID、版本号、生效日期、页码、章节，且可点击回看原文片段。
- F1.3 答案中的剂量、适应证、时间节点、方案编号等关键信息必须逐项被原文支持；任一项未支持时，系统标注"证据不足"并拒绝给出该项结论。
- F1.4 支持多轮会话，`Query Rewriter` 能结合会话实体（当前讨论的药品 / 方案）改写查询。
- F1.5 遇到同一文档多版本时，默认只使用 `active` 版本；用户显式指定历史版本时可查询 `archived` 版本，但答案必须标注"历史版本，已失效"。

F2 医学 Skills

Skill	输入	输出	风险级别
说明书查询	药品名 + 查询项（用法用量 / 禁忌 / 相互作用等）	原文片段 + 引用	低
不良事件线索提取	一段描述文本（合成 / 脱敏）	结构化 AE 要素（事件、时间、严重性、关联性线索）+ 引用依据	中
超说明书用药检查	药品 + 拟用适应证 / 剂量 / 人群	是否在说明书范围内 + 依据条款	高
方案偏离核验	方案编号 + 实际操作描述	是否偏离 + 偏离类型 + 方案条款引用	中
医学引用验证	一段带引用的陈述	每条引用是否被来源支持	低

- F2.1 每个 Skill 在 Skill Registry 注册：名称、输入输出 Schema、所需权限域、风险级别、超时、可否并行。
- F2.2 高风险 Skill 的输出必须经过 `Safety Check`，且默认附加"仅供参考、需专业人员确认"声明。

F3 知识治理

- F3.1 文档入库流程：上传 → 解析（PDF / DOCX）→ 切分（保留页码 / 章节）→ 计算来源哈希 → 写入 `draft` → 管理员审核 → `active`。
- F3.2 新版本发布时自动将旧版本置为 `archived`，并记录版本链（`supersedes`）。
- F3.3 支持按文档、版本、部门配置 ACL。
- F3.4 支持文档状态变更审计（谁、何时、从什么状态到什么状态）。

F4 安全护栏

- F4.1 拒答 / 升级触发条件：证据不足、版本冲突、越权访问、提示词注入、高风险医学问题（诊断 / 处方 / 个体用药）。
- F4.2 升级给人时保留完整上下文（问题、检索结果、Verifier 结论、触发原因）。
- F4.3 提示词注入检测覆盖用户输入和检索到的文档内容两个来源。

F5 受控自进化 Loop

- F5.1 采集信号：用户纠错、点踩、连续追问、Verifier 失败、人工升级记录。
- F5.2 归因：将 bad case 分类为 `retrieval` / `intent` / `generation` / `knowledge_gap` / `safety`。
- F5.3 候选生成：针对不同归因，自动生成 Prompt 修改、规则新增、Skill 调整或检索参数候选。
- F5.4 审批流：候选 → 历史 Trace 离线回放 → 指标对比报告 → 人工审核 → 灰度发布 → 全量 / 回滚。
- F5.5 任何候选不得绕过审批直接生效。

F6 可观测性与集成


- F6.1 每次执行产生一条 Trace：各节点输入输出、检索证据、工具调用、延迟、Token、成本。
- F6.2 Trace 可重放：给定 Trace ID 和策略版本，可离线重新执行并对比结果。
- F6.3 FastAPI 提供业务接口；MCP Server 只暴露只读检索工具，且调用方必须携带用户身份。

2.3 非功能需求

类别	指标
检索质量	Recall@5 ≥ 85% (≥300 条带版本 / 页码标注的评测样本)
引用质量	引用准确率 ≥ 95%，失效版本引用率 = 0%
安全	正确拒答率 ≥ 95%，跨部门越权拦截率 ≥ 98%，高风险问题人工升级召回率 ≥ 95% (≥150 条安全样本)
性能	普通问答 P95 ≤ 8s，复杂 Skill 工作流 P95 ≤ 15s
成本	同等质量下单次 Token 消耗降低 ≥ 25% (上下文裁剪 / 检索缓存 / 模型路由)
Loop 发布门禁	≥200 条 Trace 回放；目标任务成功率 +5pp 以上，非目标能力下降 ≤ 1pp
可审计	所有策略版本可追溯、一键回滚
可用性	单节点故障不丢任务；异步任务状态可查询、可重试

三、技术实现

3.1 总体架构



设计原则：**向量库不是事实来源**。pgvector 只负责"找候选"，最终进入上下文的每个片段都要回 PostgreSQL 验证状态、版本、权限。

3.2 Agent Harness (LangGraph)

状态定义 (Pydantic)

```
class AgentState(BaseModel):
    trace_id: str
    user: UserContext # user_id, dept, roles, acl_scopes
    query: str
    session_entities: dict # 当前会话中的药品 / 方案 / 人群等
    intent: Intent | None # 类型、目标 Skill、风险级别
    rewritten_queries: list[str]
    candidates: list[Chunk] # 检索候选 (未校验)
    evidence: list[Evidence] # 回查校验通过的证据
    verify_result: VerifyResult | None
    safety_result: SafetyResult | None
    answer: Answer | None
    escalation: Escalation | None
    policy_version: str # 当前生效的策略版本
```

节点职责

节点	职责	失败 / 降级策略
Intent	识别意图类型、映射 Skill、初判风险级别、抽取实体	意图不明确 → 反问一次；仍不明 → 走通用检索
Retrieve	调用检索链路，产出候选	超时 → 降级为仅 BM25；无候选 → 直接进 Escalate（证据不足）
Evidence Verify	回查事实平面；核验版本 / ACL；对答案要素逐项做原文支持检查	任一关键要素未支持 → 标注并剔除
Safety Check	越权、注入、高风险、无依据结论检测	命中 → Escalate
Answer	基于证据生成答案，强制引用格式	生成后二次核验引用是否存在于 evidence
Escalate	生成人工升级工单，附完整上下文	—

工程控制

- 每个节点声明输入输出 Schema，进出节点时校验，不合法直接进入失败分支。
- 超时 + 重试（指数退避，最多 2 次），重试键 = trace_id + node + attempt，保证幂等。
- 节点执行不允许"直连 LLM 生成最终答案"：Answer 节点只接受来自 Evidence Verify 的证据作为上下文。
- Trace 重放：Trace 记录每个节点的输入快照，重放时可替换策略版本 / 检索参数重跑。

Skill Registry

```
@skill(  
    name="off_label_check",  
    input_schema=OffLabelInput,  
    output_schema=OffLabelOutput,  
    required_scopes=["MA:read"],  
    risk="high",  
    timeout_s=20,  
    parallel_safe=True,  
)  
async def off_label_check(inp, ctx): ...
```

Registry 在运行时检查调用方 acl_scopes 是否覆盖 required_scopes，不满足直接拒绝，不进入执行。

3.3 知识层：事实平面数据模型

```
documents (  
    doc_id          uuid PK,  
    family_id       uuid,          -- 同一文档的所有版本共享  
    title           text,  
    doc_type        enum('label','protocol','sop','guideline'),  
    version         text,  
    status          enum('draft','active','archived'),  
    effective_from  date,  
    effective_to    date,  
    source_hash     text,          -- sha256, 防篡改 / 去重  
    supersedes      uuid,          -- 版本链  
    owner_dept      text,  
    created_by      uuid, created_at timestamptz,  
    status_changed_by uuid, status_changed_at timestamptz  
)  
  
chunks (  
    chunk_id  uuid PK,  
    doc_id    uuid FK,  
    page      int,  
    section   text,          -- "4.2 用法用量"  
    seq       int,  
    content   text,  
    tsv       tsvector,      -- BM25 / 全文检索  
    embedding  vector(1024)  -- pgvector  
)  
  
document_acl (doc_id, dept, permission enum('read'))  
  
doc_audit (id, doc_id, from_status, to_status, actor, at, reason)  
  
evidence_log (trace_id, chunk_id, doc_id, version, page, section, verified bool)
```

关键约束：

- chunks 无 status 字段，状态只在 documents 上，避免不一致。
- 检索时 SQL 层强制 JOIN documents WHERE status='active' AND doc_id IN (acl for user.dept)，权限过滤在数据库完成而非应用层过滤。
- 同一 family_id 在任一时刻只允许一个 active（唯一部分索引）。

3.4 检索链路



设计要点：

- BM25 侧对药品名、剂量单位 (mg / mL / µg)、时间窗表达 ("14 天内")、方案编号 (如 PROT-2024-017) 做专门分词，避免被向量语义"模糊掉"。
- 检索缓存: hash(rewritten_query + user.dept + policy_version) 为 key, Redis 缓存候选 (TTL 短, 文档状态变更时按 family_id 失效)。
- 术语表存 PostgreSQL, Loop 可提出新增映射候选。

3.5 Verifier

两层核验：

- 结构核验：答案中每条引用的 (doc_id, version, page) 必须存在于本次 evidence 列表；不存在即判定"幻觉引用"。
- 要素核验：从答案中抽取关键要素（剂量、频次、适应证、人群、时间节点、编号），对每个要素找到支撑它的证据片段，用 NLI / 小模型判断 supported / not_supported / contradicted。
 - not_supported → 从答案中删除该要素并标注
 - contradicted → 整条答案拒绝，进 Escalate（可能是版本冲突）


Verifier 结果写入 Trace，作为 Loop 的重要信号源。

3.6 安全护栏

检测项	实现	动作
越权访问	意图中提到的文档域 / Skill 与用户 scopes 不匹配	拒答 + 审计记录
提示词注入	用户输入 + 检索片段均过分类器 + 规则 ("忽略以上指令""你现在是…"等)；检索片段一律以数据形式注入，不作指令	剔除片段 / 拒答
高风险医学问题	意图分类：诊断、处方、个体剂量调整、紧急医疗	拒答 + 人工升级
无依据医学结论	Verifier not_supported 比例超阈值	拒答
版本冲突	同一要素在不同版本证据中矛盾	升级

原则：护栏不是单一节点，而是检索层（ACL）+ Verify 层（证据）+ Safety 节点（意图）三处叠加。

3.7 受控自进化 Loop



工程约束：

- 策略 (Prompt / Rule / Skill 配置 / 检索参数) 全部版本化存储在 PostgreSQL policies 表，生产运行时只读取 status='released' 的版本。
- Loop 进程没有写 released 状态的权限，只能写 candidate；released 只能由审核员通过后台操作。
- 每次发布记录 policy_version 到后续所有 Trace，回滚即切换指针。

3.8 评测体系

数据集	规模	构建方式	覆盖指标
检索 / 引用评测集	≥300	从入库文档人工标注 Q + 正确 (doc, version, page)	Recall@5、引用准确率、失效版本引用率
安全评测集	≥150	越权、注入、无依据结论、高风险问题四类	拒答率、拦截率、升级召回率
Trace 回放集	≥200	从生产 Trace 采样，含 bad case 和 good case	Loop 门禁指标
性能基线	—	压测脚本	P95 延迟、Token

评测在 CI 中运行：任何 Prompt / 检索参数 / Skill 的 PR 必须附带评测结果。

3.9 可观测性

- Langfuse：记录 Trace / Span / Generation，关联 trace_id、policy_version、user.dept（不记录用户明文身份）。
- OpenTelemetry：FastAPI、PostgreSQL、Redis、LLM 调用的 span 与指标，导出至 OTLP collector。
- 每个 Trace 必须包含：检索候选列表、校验后证据、Verifier 逐项结果、Safety 结果、各节点耗时、Token 与成本估算。

3.10 服务与集成

FastAPI 接口（核心）

接口	说明
POST /v1/ask	同步问答（普通问题）
POST /v1/tasks	提交异步 Skill 工作流，返回 task_id
GET /v1/tasks/{id}	查询 queued / running / completed / failed
POST /v1/tasks/{id}/retry	失败重试
POST /v1/feedback	点踩 / 纠错
POST /admin/documents PATCH /admin/documents/{id}/status	文档入库 / 状态变更
GET /admin/policies/candidates POST /admin/policies/{id}/approve	Loop 审批
POST /admin/traces/{id}/replay	Trace 重放

异步执行：Redis 作为任务队列（或 arq / Celery），worker 从队列消费，状态持久化到 PostgreSQL tasks 表，支持进度回写。

MCP Server（只读）

- 暴露工具：search_documents、get_chunk、verify_citation、list_active_versions。
- 调用方必须传递用户身份 token，MCP Server 解析出 dept / scopes 后调用同一套检索链路（走相同 ACL 过滤）。
- 不暴露任何写操作，不暴露 draft / archived 文档（除非显式请求历史版本且有权限）。

3.11 成本与性能优化

手段	说明
上下文裁剪	只把 Verifier 通过的证据放入 Answer 上下文；每片段截取相关句子而非整块
检索缓存	Redis 缓存查询 → 候选映射
模型路由	Intent / Verifier 用小模型；Answer 按风险级别和证据复杂度选大 / 小模型
并行	BM25 与 pgvector 并行；多 Skill 并行调用（parallel_safe=True）+ 部分结果合并
Reranker 本地化	cross-encoder 本地推理，避免额外 API 往返

四、约束

4.1 安全与合规约束（硬约束）

1. **不提供诊断、处方、个体化用药建议。**任何此类意图直接拒答 + 升级，不做"软性回答"。
2. **不处理真实患者数据。**所有输入 / 文档 / 评测样本必须是公开、脱敏或合成数据；入库前检查是否含 PII 模式。
3. **零失效版本引用。**任何引用必须在 active 状态（或用户显式请求历史版本并标注）。
4. **权限在数据库层强制执行**，应用层不得"先查再过滤"。
5. **检索到的文档内容只能作为数据，不能作为指令。**
6. **生产策略只能由人工审批后变更。**Loop 无写权限。
7. **每次回答可审计：**Trace 中保留完整证据链，保留期不少于项目要求。
8. **对外声明：**所有答案附"基于文档检索，仅供专业人员参考"的固定声明。

4.2 数据约束

- 文档解析必须保留页码与章节结构，无法保留的文档标记为"低可信"，不进入 active。
- 同一 family_id 同一时刻只能有一个 active 版本。
- source_hash 变更视为新文档版本，不允许原地覆盖。
- 评测集与训练 / 调优数据严格隔离，评测样本不进入 Loop 的候选生成上下文。

4.3 工程约束

- 所有节点输入输出必须有 Pydantic Schema，禁止 dict[str, Any] 直传。
- 节点之间只通过 AgentState 传递，禁止全局变量或副作用。
- 任何外部调用（LLM、Reranker、DB）必须有超时；LLM 调用必须有 max_tokens。
- Skill 必须在 Registry 注册才可被调用，禁止在节点内直接 import 调用。
- 策略、术语表、规则均版本化；代码库中不存放 Prompt 明文的"最新版"作为唯一来源。
- Docker 化部署；配置通过环境变量注入，密钥不进仓库。

4.4 性能与成本约束

- 普通问答 P95 ≤ 8s；复杂 Skill 工作流 P95 ≤ 15s。
- 单次问答 Token 上限（含检索上下文）设硬阈值，超出时先裁剪证据而非放宽限制。
- Reranker 候选数上限 20，进入上下文的证据片段上限 8。

4.5 Loop 发布门禁（硬约束）

- 回放样本 ≥ 200 条，且包含安全评测集全量。
- 目标任务成功率提升 ≥ 5pp。

- 任何非目标任务下降 > 1pp 即拒绝。
- 任何安全指标下降即拒绝。
- 必须有审核员人工签字；灰度比例初始 $\leq 10\%$ 。
- 回滚必须在一次操作内完成（切换 `policy_version` 指针）。

4.6 范围约束（当前阶段不做）

- 不做多模态（图表、影像）。
- 不做文档在线编辑 / 协作。
- 不做跨租户部署。
- 不做实时流式 Loop（Loop 以批次离线运行）。

五、里程碑建议

阶段	交付	验收
M1 知识层	事实平面 + 入库流程 + ACL + 混合检索	Recall@5 $\geq 85\%$ ，失效引用 = 0
M2 Harness	LangGraph 状态机 + Verifier + Safety + Skill Registry + 2 个 Skill	引用准确率 $\geq 95\%$ ，安全集通过
M3 服务与观测	FastAPI + 异步任务 + Langfuse / OTel + MCP Server	P95 达标，Trace 可重放
M4 Loop	Observe / Reflect / Adapt + 回放 + 审批后台 + 灰度	完成一轮带门禁的策略发布并可回滚
M5 全量 Skill 与优化	剩余 Skill + 成本优化	Token 降 $\geq 25\%$ ，全部验收指标达成

六、待决策事项

1. Embedding 模型与 Reranker 选型（中英文医学语料表现、本地部署可行性）。
2. Verifier 的 NLI 模型：用小 LLM 还是专用 NLI 模型。
3. 异步框架：arq / Celery / 自研轻量 worker。
4. 术语表初始来源（公开药典 / 通用名对照表）。
5. 灰度维度：按用户还是按部门。